

Bank Marketing Data Analysis

Umut Aykanat

- GİRİŞ
- Veri Seti Hakkında Betimleyici Bilgiler
 - Veri Tipi Dönüşümü
 - Keşifçi Veri Analizi ve Görselleştirme
- Hangi değişken modele daha fazla katkı sağlamış?
- Model Tahminleri
- GLM MODEL İYİLEŞTİRME
- Optimal Cut_off Value
- İKİNCİ MODELİN KURULMASI
- Accuracy
- Recall
- Precision
- Sensitivity
- Specificity
- F1 Scoru
- ROC CURVE
- Sonuç: Elde Edilen Tahmin Denklemi ve Yorumlanması
 - Değişkenler Arasındaki Korelasyon Katsayıları
 - Modelin Test Seti Tahminleri

■ TEŞEKKÜRLER

GİRİŞ

Bu proje, Portekiz'de bir bankanın doğrudan pazarlama kampanyaları sırasında toplanan müşterileri verilerini analiz etmeyi amaçlamaktadır. Veri seti, müşterilerin demografik özellikleri (yaş, medeni durum, eğitim düzeyi), finansal durumları (bakiye, kredi geçmişi, konut ve kişisel kredi durumu) ve banka ile iletişim bilgilerini içermektedir.

Projenin temel hedefi, müşterilerin **vadeli mevduat (term deposit)** teklifini kabul edip etmemelerini etkileyen faktörleri incelemektir. Böylece pazarlama kampanyalarının başarısını artırabilecek değişkenler belirlenebilir.

Veri setinde toplam 17 değişken bulunmaktadır. Bunlardan 16'sı açıklayıcı (bağımsız) değişken, biri ise hedef (bağımlı) değişkendir:

- **Bağımlı değişken:** y - Müşteri vadeli mevduat teklifini kabul etti mi? ("yes" veya "no")
- **Bağımsız değişkenler:** yaş, meslek, eğitim durumu, kredi durumu, iletişim tipi, kampanya süresi vb.

Bu analiz kapsamında; - Değişkenlerin yapısı incelenmiş,

- Kategorik değişkenler görselleştirilmiş,
- Temel özet istatistikler sunulmuş,

Sonuç olarak proje, pazarlama stratejilerinin daha veriye dayalı ve hedef odaklı hale gelmesine katkı sağlayabilecek içgörüler sunmaktadır.

```
data <- read.csv("/Users/umutaykanat/Desktop/portfolio/banking data/train.csv", sep = ";", header = TRUE)
head(data)
```

```
1
2
3
4
5
6
```

6 rows | 1-1 of 18 columns

Veri Seti Hakkında Betimleyici Bilgiler

```
str(data)
```

```

## 'data.frame': 45211 obs. of 17 variables:
## $ age      : int 58 44 33 47 33 35 28 42 58 43 ...
## $ job       : chr "management" "technician" "entrepreneur" "blue-collar" ...
## $ marital   : chr "married" "single" "married" "married" ...
## $ education: chr "tertiary" "secondary" "secondary" "unknown" ...
## $ default   : chr "no" "no" "no" "no" ...
## $ balance   : int 2143 29 2 1506 1 231 447 2 121 593 ...
## $ housing   : chr "yes" "yes" "yes" "yes" ...
## $ loan      : chr "no" "no" "yes" "no" ...
## $ contact   : chr "unknown" "unknown" "unknown" "unknown" ...
## $ day       : int 5 5 5 5 5 5 5 5 ...
## $ month     : chr "may" "may" "may" "may" ...
## $ duration  : int 261 151 76 92 198 139 217 380 50 55 ...
## $ campaign  : int 1 1 1 1 1 1 1 1 ...
## $ pdays     : int -1 -1 -1 -1 -1 -1 -1 -1 -1 ...
## $ previous  : int 0 0 0 0 0 0 0 0 ...
## $ poutcome  : chr "unknown" "unknown" "unknown" "unknown" ...
## $ y         : chr "no" "no" "no" "no" ...

```

Verimiz 45211 gözlem ve 17 değişkenden oluşuyor. Değişkenleri tanıyalım: **age**: Müşterinin yaşı **job**: İş türü **marital**: Medeni durumu **education**: Eğitim düzeyi **default**: Kredi temerrüt durumu **balance**: Ortalama yıllık bakiye(€) **housing**: Konut kredisi durumu **loan**: Kişisel kredi durumu **contact**: İletişim Türü **day**: Ayın son iletişim günü **month**: Son iletişim ayı **duration**: Son iletişim süresi **campaign**: Kampanya süresince yapılan iletişim sayısı **pdays**: Önceli kampanyadan sonra geçen gün sayısı **previous**: Bu kampanyadan önce yapılan iletişim sayısı **poutcome**: Önceli pazarlama kampanyasının sonucu **y**: Müşteri vadeli mevduata abone oldu mu?

Veri Tipi Dönüşümü

Kategorik değişkenleri factor olarak belirleyelim

```

# Tüm karakter tipindeki değişkenleri faktöre çevir
data[sapply(data, is.character)] <- lapply(data[sapply(data, is.character)], as.factor)
str(data)

```

```

## 'data.frame': 45211 obs. of 17 variables:
## $ age      : int 58 44 33 47 33 35 28 42 58 43 ...
## $ job      : Factor w/ 12 levels "admin.", "blue-collar", ...: 5 10 3 2 12 5 5 3 6 10 ...
## $ marital  : Factor w/ 3 levels "divorced", "married", ...: 2 3 2 2 3 2 3 1 2 3 ...
## $ education: Factor w/ 4 levels "primary", "secondary", ...: 3 2 2 4 4 3 3 3 1 2 ...
## $ default   : Factor w/ 2 levels "no", "yes": 1 1 1 1 1 1 2 1 1 ...
## $ balance   : int 2143 29 2 1506 1 231 447 2 121 593 ...
## $ housing   : Factor w/ 2 levels "no", "yes": 2 2 2 2 1 2 2 2 2 2 ...
## $ loan      : Factor w/ 2 levels "no", "yes": 1 1 2 1 1 1 2 1 1 ...
## $ contact   : Factor w/ 3 levels "cellular", "telephone", ...: 3 3 3 3 3 3 3 3 3 3 ...
## $ day       : int 5 5 5 5 5 5 5 5 ...
## $ month     : Factor w/ 12 levels "apr", "aug", "dec", ...: 9 9 9 9 9 9 9 9 9 9 ...
## $ duration  : int 261 151 76 92 198 139 217 380 50 55 ...
## $ campaign  : int 1 1 1 1 1 1 1 1 ...
## $ pdays     : int -1 -1 -1 -1 -1 -1 -1 -1 -1 ...
## $ previous  : int 0 0 0 0 0 0 0 0 ...
## $ poutcome  : Factor w/ 4 levels "failure", "other", ...: 4 4 4 4 4 4 4 4 4 4 ...
## $ y         : Factor w/ 2 levels "no", "yes": 1 1 1 1 1 1 1 1 ...

```

Keşifçi Veri Analizi ve Görselleştirme


Öncelikle hedef değişkenin dağılımına bakalım

```

library(ggplot2)
# Y değişkeninin oranlarını tablo haline getirelim
y_data <- as.data.frame(table(data$y))
colnames(y_data) <- c("y", "count")
# Pasta grafiği
ggplot(y_data, aes(x = "", y = count, fill = y)) +
  geom_col(width = 1, color = "white") +
  coord_polar(theta = "y") +
  labs(title = "Müşteri Mevduat Kabul Oranı (y değişkeni)",
       fill = "Mevduat Durumu") +
  theme_void() +
  geom_text(aes(label = paste0(round(count / sum(count) * 100, 1), "%")),
            position = position_stack(vjust = 0.5),
            color = "white",
            size = 5)

```

Müşteri Mevduat Kabul Oranı (y değişkeni)



durumunun tüm müşteriler bazında dağılımı %11.7 evet iken %88.3 hayatırdır. Hedef değişkenin dağılımında eşitsizlik olduğu göz önünde bulundurulmalıdır.

Her değişkenin alt kategorilerine ait müşteri mevduat oranlarını inceleyelim. Bu oranlar tekil incelendiğinde anlamlıdır. Örneğin kişinin yalnızca medeni durumuna göre analiz yapıılırsa mevduata abone olma durumu %6.1 iken olmama durumu %54.1'dir.

Değişkenlerin kategorilerinin kendi aralarında müşteri mevduat oranlarını inceleyelim:

```
library(dplyr)

## 
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
## 
##     filter, lag

## The following objects are masked from 'package:base':
## 
##     intersect, setdiff, setequal, union
```

```

library(ggplot2)
library(forcats)
library(rlang)

cat_vars <- names(data)[sapply(data, is.factor)]
custom_colors <- c("no" = "#ff6b6b", "yes" = "#1dd1a1")




for (var in cat_vars) {
  p_data <- data %>%
    group_by(across(all_of(var)), y) %>%      # kategori ve y'ye göre say
    summarise(count = n(), .groups = "drop") %>%
    group_by(across(all_of(var))) %>%          # kategori bazında topla
    mutate(percent = count / sum(count) * 100) %>%
    ungroup()

  # label sütunu (% formatında)
  p_data <- p_data %>% mutate(label = sprintf("%.1f%%", percent))


  p <- ggplot(p_data, aes(x = fct_reorder(as.factor (!!sym(var))), percent, .fun = max),
              y = percent, fill = y, label = label)) +
    geom_col(position = position_dodge(width = 0.9), width = 0.7) +
    geom_text(position = position_dodge(width = 0.9),
              vjust = -0.25, size = 3.5, color = "black") +
    coord_flip() +
    scale_fill_manual(values = custom_colors) +
    labs(title = paste("Term Deposit Dağılımı -", var),
         x = var, y = "Yüzde (%)", fill = "Term Deposit") +
    theme_minimal(base_size = 13) +
    theme(plot.title = element_text(face = "bold", hjust = 0.5),
          legend.position = "bottom")

  print(p)
}


```




Term Deposit Dağılımı - default




Term Deposit Dağılımı - housing




Term Deposit Dağılımı - loan



Term Deposit Dağılımı - contact




Term Deposit Dağılımı - month




Term Deposit ■ no ■ yes

Term Deposit Dağılımı - poutcome



Term Deposit ■ no ■ yes

Term Deposit Dağılımı - y



Kayıp gözlem kontrolü:

```
sum(is.na(data)) # kayıp gözlem görünmüyör.
```

```
## [1] 0
```

Bu aşamada y değişkenini tahmin etmek üzere regresyon modeli kurup tahmin yapacağız

Bağımlı değişkenin dağılımı:

```
table(data$y)
```

```
##  
##   no   yes  
## 39922  5289
```

Bağımlı değişkenimizin alt kategorilerini incelediğimizde ret sayısının kabul sayısından yaklaşık 7.5 kat fazla olduğu görülmektedir. Tahmin modelini eğitirken bu dengesizliğin yaratacağı yanılığın önüne geçmek adına eğitim kümesine eşit sayıda kabul ve ret içeren gözlemleri dahil etmek gerekmektedir. Bu işlem yalnızca eğitim kümesinde gerçekleştirilecek ve test kümesine müdahale edilmeyecektir.

Eğitim setine yeterli sayıda kabul ve ret alabilmek adına düzenlemeler yapalım:

```
library(dplyr)  
dataYes <- data %>% filter(y == "yes")  
dataNo <- data %>% filter(y == "no")  
nrow(dataYes) ; nrow(dataNo)
```

```
## [1] 5289
```

```
## [1] 39922
```

```
set.seed(111)  
dataNoIndex <- sample(1:nrow(dataNo), size = 0.8*nrow(dataYes))  
set.seed(111)  
dataYesIndex <- sample(1:nrow(dataYes), size = 0.8*nrow(dataYes))  
  
trainYes <- dataYes[dataYesIndex, ]  
trainNo <- dataNo[dataNoIndex, ]  
  
# Şimdi rbind kullanarak alt gruplardan ayrı ayrı aldığımız örneklemeleri satır bazında birlestirelim.  
trainset<-rbind(trainYes,trainNo)  
table(trainset$y) # eşit sayıda no ve yes içeren gözlemi train sete dahil etmiş olduk.
```

```
##  
##   no   yes  
## 4231  4231
```

Aynı işlemleri test seti için de yapalım

```
testYes <- dataYes[-dataYesIndex,]  
testNo <- dataNo[-dataNoIndex,]  
  
testset<-rbind(testYes, testNo)  
table(testset$y)
```

```
##  
##    no    yes  
## 35691 1058
```

GLMNET yöntemi ile ilk modeli kuralım

```
library(glmnet)
```

```
## Loading required package: Matrix
```

```
## Loaded glmnet 4.1-8
```

```
model_glm <- glm(y ~. , family = "binomial", data = trainset)  
summary(model_glm)
```

```

## 
## Call:
## glm(formula = y ~ ., family = "binomial", data = trainset)
##
## Coefficients:
##                               Estimate Std. Error z value Pr(>|z|)
## (Intercept)           -8.686e-01 3.069e-01 -2.831  0.00464 **
## age                  -2.018e-03 3.648e-03 -0.553  0.58010
## jobblue-collar      -5.411e-01 1.213e-01 -4.462 8.11e-06 ***
## jobentrepreneur     -2.643e-01 2.010e-01 -1.315  0.18861
## jobhousemaid        -5.992e-01 2.277e-01 -2.632  0.00848 **
## jobmanagement       -1.707e-01 1.260e-01 -1.355  0.17554
## jobretired          3.544e-01 1.707e-01  2.076  0.03793 *
## jobsself-employed   -5.323e-01 1.822e-01 -2.922  0.00348 **
## jobservices         -3.794e-01 1.419e-01 -2.674  0.00750 **
## jobstudent          5.454e-01 2.030e-01  2.686  0.00723 **
## jobtechnician       -1.382e-01 1.169e-01 -1.183  0.23698
## jobunemployed       -2.677e-01 1.908e-01 -1.403  0.16063
## jobunknowm          1.416e-02 4.041e-01  0.035  0.97205
## maritalmarried      -7.655e-02 9.857e-02 -0.777  0.43740
## maritalsingle       2.030e-01 1.132e-01  1.792  0.07306 .
## educationsecondary  1.143e-01 1.076e-01  1.062  0.28831
## educationtertiary   2.810e-01 1.267e-01  2.217  0.02664 *
## educationunknown    4.340e-02 1.779e-01  0.244  0.80726
## defaultyes          -1.935e-01 2.579e-01 -0.750  0.45312
## balance              1.963e-05 1.018e-05  1.929  0.05369 .
## housingyes          -8.207e-01 7.213e-02 -11.378 < 2e-16 ***
## loanyes              -6.908e-01 9.605e-02 -7.191 6.41e-13 ***
## contacttelephone    -2.571e-01 1.309e-01 -1.963  0.04960 *
## contactunknowm      -1.685e+00 1.131e-01 -14.893 < 2e-16 ***
## day                  6.910e-03 4.111e-03  1.681  0.09280 .
## monthaug             -8.964e-01 1.290e-01 -6.947 3.74e-12 ***
## monthdec              1.114e+00 4.326e-01  2.576  0.01001 *
## monthfeb             7.448e-02 1.491e-01  0.499  0.61743
## monthjan             -1.351e+00 1.939e-01 -6.966 3.26e-12 ***
## monthjul             -1.115e+00 1.290e-01 -8.645 < 2e-16 ***
## monthjun             2.319e-01 1.539e-01  1.507  0.13171
## monthmar             1.599e+00 2.366e-01  6.756 1.41e-11 ***
## monthmay             -6.390e-01 1.236e-01 -5.172 2.32e-07 ***
## monthnov             -8.765e-01 1.401e-01 -6.257 3.92e-10 ***
## monthoct              1.165e+00 2.082e-01  5.593 2.23e-08 ***
## monthsep              1.449e+00 2.736e-01  5.297 1.17e-07 ***
## duration              5.865e-03 1.519e-04 38.623 < 2e-16 ***
## campaign             -8.714e-02 1.563e-02 -5.577 2.45e-08 ***
## pdays                 -1.308e-05 4.907e-04 -0.027  0.97873
## previous              4.243e-02 1.828e-02  2.321  0.02029 *
## poutcomeother        3.996e-01 1.558e-01  2.566  0.01030 *
## poutcomesuccess      2.237e+00 1.620e-01 13.813 < 2e-16 ***
## poutcomeunknowm      -2.845e-02 1.621e-01 -0.176  0.86065
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 11730.8 on 8461 degrees of freedom
## Residual deviance: 6686.7 on 8419 degrees of freedom
## AIC: 6772.7
##
## Number of Fisher Scoring iterations: 6

```

Çıktıda modelin anlamlı (p-value < alpha) olduğu görülmektedir. NullDeviance(Boş modelin sapması) = 11730.8 elde edilirken, modele değişkenler eklenliğinde ResidualDeviance(Artıkların sapması) = 6686.7 olarak daha iyi bir model elde edilmişdir. Yani **bağımsız değişkenlerin eklenmesi modeli iyileştirmiştir**. Her bir değişkenin modele katkılarını ve değişkenlerin anlamlı olup olmadıklarını basitçe çıktıdaki * sayısından yorumlayabiliriz.

Modele katkısı olmayan veya katkısı az olan değişkenlerin model çıkarılması model karmaşıklığını düşürmek adına fayda sağlayacaktır. İlerleyen aşamalarda bu işlemlere yer verilecektir.

Elde edilen model katsayıları hakkında daha detaylı yorumlar yapabilmek adına $\exp(\beta)$ katsayıları elde edilmelidir.

```
exp(coef(model_glm))
```

```

##      (Intercept)          age jobblue-collar jobentrepreneur
## 0.4195240        0.9979837    0.5820974     0.7677620
## jobhousemaid   jobmanagement jobretired    jobself-employed
## 0.5492265        0.8430387    1.4252747     0.5872415
## jobservices    jobstudent   jobtechnician  jobunemployed
## 0.6843038        1.7253149    0.8708816     0.7651186
## jobunknowm   maritalmarried maritalsingle educationsecondary
## 1.0142613        0.9263087    1.2250589     1.1210819
## educationtertiary educationunknown defaultyes   balance
## 1.3244210        1.0443585    0.8240944     1.0000196
## housingyes    loanyes contacttelephone contactunknown
## 0.4401284        0.5011905    0.7733229     0.1854430
## day           monthaug   monthdec      monthfeb
## 1.0069337        0.4080273    3.0468524     1.0773202
## monthjan     monthjul   monthjun      monthmar
## 0.2589776        0.3279464    1.2610269     4.9468424
## monthmay     monthnov   monthoctxt  monthsep
## 0.5278018        0.4162537    3.2049005     4.2607833
## duration       campaign  pdays previous
## 1.0058819        0.9165520    0.9999869     1.0433427
## poutcomeother poutcomesuccess poutcomeunknown
## 1.4912731        9.3662918    0.9719526

```

Bu değerler odds oranıdır. Katsayı 1'in altındaysa azaltıcı, 1'e eşitse etkisi aynı(fark yok), 1'den fazlaysa etkisi fazladır yorumu yapılabilir.

Pseudo_r2 değeri:

```
library(pscl)
```

```

## Classes and Methods for R originally developed in the
## Political Science Computational Laboratory
## Department of Political Science
## Stanford University (2002-2015),
## by and under the direction of Simon Jackman.
## hurdle and zeroinfl functions by Achim Zeileis.

```

```
pseudo_r2 = pscl:::pR2(model_glm)[ "McFadden" ]
```

```
## fitting null model for pseudo-r2
```

```
pseudo_r2
```

```

## McFadden
## 0.4299881

```

0.40'tan büyük Pseudo_r2 değeri modelin anlamlı tahminler yaptığıını işaret eder. Kurduğumuz model anlamlı tahminler yapabilimiştir!

Hangi değişken modele daha fazla katkı sağlamış?

Bu yorumu yapabilmek için Resid. Dev kısmındaki değeri en çok hangi değişkenlerin düşürdüğü incelenir.

```
anova(model_glm)
```

```
NULL
```

```
age
```

```
job
```

```
marital
```

```
education
```

```
default
```

```
balance
```

```
housing
```

```
loan
```

```
contact
```

Değerler incelediğinde modelin summary'sinde de olduğu gibi anlamlı çıkan değişkenlerin modele katkısının daha yüksek olduğunu görüyoruz. Tüm değişkenler incelediğinde complexity'ide azaltmak için etkisi az olan değişkenleri modelden çıkarabiliriz. Modelin karmaşıklıktan uzak olması istedigimiz bir şeydir.

Model Tahminleri

```

predict1<-predict(model_glm,testset,type="response")
head(predict1)

##      8       9      10      11      13      16
## 0.9098142 0.9982538 0.3324927 0.9985782 0.9653114 0.4211302

library(devtools)

## Loading required package: usethis

cm<-InformationValue::confusionMatrix(testset$y, predictedScores = predict1)
cm

```

0
1

2 rows | 1-1 of 3 columns

Sütun isimlerinde yer alan No ve Yes değerleri test setinde yer alan gerçek değerleri, satır isimlerinde yer alan **0** değeri model tahmininde **No** olarak belirlenen tahminleri, **1** değeri ise **Yes** olarak belirlenen tahminleri ifade etmektedir.

confusion matrix incelediğinde **model_glm** doğru negatifleri(30238 tahmin) tespit etmekte oldukça başarılı görünüyor. Başka bir deyişle **model_glm** mevduata abone olmama durumunu doğru tahmin etmekte başarılı ancak mevduata abone olma durumunu doğru tahmin etmekte iyileştirmeler yapılabilir. Bu değerlendirmeleri **accuracy(doğruluk)** ve **errorrate(hata oranı)** metriklerinde de inceleyelim:

Accuracy toplam gözlem sayısının doğru atamalara oranlanması ile edle edilen bir metricdir.

```

accuracy1<-(cm[2,2]+cm[1,1])/sum(cm)
accuracy1

## [1] 0.845955

```

accuracy metriği doğru tahminlerin tüm tahminlere oranlamasıyla elde edillir. Tahminlerde %84 doğruluk oranı sağlanmış olmasına karşın yanlış negatiflerin çok olması durumu iyileştirilebilir.

Bir de **Error Rate**(hata oranına) bakalım. Hata oranı yanlış atamaların toplam gözlem sayısına oranlanmasıyla elde edilir.

```

errorRate1<-(cm[1,2]+cm[2,1])/sum(cm)
errorRate1

## [1] 0.154045

```

Hata oranı %15 olarak elde edildi. Yani model1 ile bir tahminde bulunulduğunda %85 doğru %15 yanlış bir sonuç elde edilecektir.

GLM MODEL İYİLEŞTİRMEŞİ

Optimal Cut_off Value

```

# install.packages("InformationValue")
library(InformationValue)

optCutoff<-InformationValue::optimalCutoff(testset$y,predictedScores=predict1)
optCutoff

## [1] 0.009999996

```

Esik değeri çok küçük bulunmaktadır 0.0099. Burda **optCutt_off** point belirlenirken dikkate alınan metric **accuracy** dir. Fakat probleme göre veriye göre bu durum değişiklik gösterebilir. Yani accuracy'ye göre **cutoff_point** belirlememiz bazen yanlıltıcı olabilir. Testte iyi sonuçlar verirken gerçek

hayat probleminde elde edilen cutoff_pointe göre sonuçlar gerçeği yansıtmayabilir. Ve cutoff-point'in belirlenmesi bazen araştırcıya da bırakılabilir. Şimdi bu optimal cutoff noktasına göre confusion matrixi yeniden oluşturursak;

```
cmOpt<-InformationValue::confusionMatrix(testset$y,predictedScores = predict1,  
                                         threshold =optCutoff )  
cmOpt      # threshold değerini optcutoff yaptı.
```

```
0  
1  
2 rows | 1-1 of 3 columns
```

```
accuracyopt<-(cmOpt[2,2]+cmOpt[1,1])/sum(cmOpt)  
accuracyopt; cm; cmOpt
```

```
## [1] 0.041661
```

```
0  
1  
2 rows | 1-1 of 3 columns
```

```
0  
1  
2 rows | 1-1 of 3 columns
```

Bu noktada cutoff_pointe göre atandığında **positive-positive** oranı artmış fakat **negative-negative** oranı düşmüştür. Accuracy değerinin de düşüğü görülmektedir. Bu noktada amaca göre doğru eşik değeri belirlenmelidir. Araştırma bazında hangi metriğin kritik rol aldığına bağlı olarak cutt_off değeri ayarlanabilir. Örneğin doğru-pozitifleri yakalamanın önemli olduğu hastalık teşhis gibi durumlar olabilir. Bu durum test verisi üzerinde inceleme yaparak karar verelebilir.

Daha önce belirtildiği gibi yanlış negatiflerin(Tip I hata) sebebini inceleyelim:

```
summary(predict1)
```

```
##      Min.    1st Qu.     Median      Mean    3rd Qu.      Max.  
## 0.0001522 0.0695097 0.1622704 0.2603437 0.3630364 1.0000000
```

model_glm kullanılarak elde edilen tahminlerin medyan değeri 0.16 gibi düşük bir değer gelmiştir. Default(varsayılan) olarak 0.5 odds oranı ile çalıştığımız için bu sonuç ortaya çıkmış olabilir. Optimal cut_off value belirleyerek bu konuda iyileştirme yapılabilir. İlerleyen aşamalarda bu konuya değinilecektir.

İKİNCİ MODELİN KURULMASI

Daha az bağımsız değişkenle daha iyi bir model kurmak pek çok açıdan avantajlı bir durumdur. Daha basit bir model kurmak adına değişken sayısını azaltılabilir. Anlamlı değişkenlerle modeli tekrar kurup daha iyi bir model elde etmeye çalışalım:

```
new_train_set <- trainset %>% select(job,marital,education,default,balance,housing,loan,contact,day,month,duration,  
n,campaign,pdays,previous,poutcome,y)  
head(new_train_set)
```

```
979  
175  
2841  
699  
2117
```

6 rows | 1-1 of 17 columns

```

model_glm2 <- glm(y ~.,
  family = "binomial", data = new_train_set)
summary(model_glm2)

## 
## Call:
## glm(formula = y ~ ., family = "binomial", data = new_train_set)
## 
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -9.633e-01  2.548e-01 -3.781 0.000156 ***
## jobblue-collar -5.387e-01  1.212e-01 -4.445 8.78e-06 ***
## jobentrepreneur -2.665e-01  2.009e-01 -1.326 0.184738
## jobhousemaid -6.093e-01  2.271e-01 -2.684 0.007282 **
## jobmanagement -1.737e-01  1.259e-01 -1.380 0.167735
## jobretired     3.145e-01  1.549e-01  2.031 0.042270 *
## jobsself-employed -5.331e-01  1.822e-01 -2.926 0.003431 **
## jobservices    -3.789e-01  1.419e-01 -2.671 0.007568 **
## jobstudent      5.648e-01  2.000e-01  2.824 0.004743 **
## jobtechnician   -1.398e-01  1.169e-01 -1.196 0.231568
## jobunemployed   -2.679e-01  1.908e-01 -1.404 0.160372
## jobunknowm     5.612e-03  4.040e-01  0.014 0.988918
## maritalmarried -7.255e-02  9.831e-02 -0.738 0.460528
## maritalsingle   2.245e-01  1.064e-01  2.110 0.034858 *
## educationsecondary 1.200e-01  1.072e-01  1.120 0.262822
## educationtertiary 2.893e-01  1.259e-01  2.298 0.021556 *
## educationunknown 4.207e-02  1.779e-01  0.236 0.813089
## defaultyes     -1.913e-01  2.580e-01 -0.742 0.458307
## balance         1.913e-05  1.013e-05  1.887 0.059124 .
## housingyes     -8.176e-01  7.191e-02 -11.371 < 2e-16 ***
## loanyes          -6.892e-01  9.601e-02 -7.178 7.07e-13 ***
## contacttelephone -2.675e-01  1.296e-01 -2.064 0.039025 *
## contactunknowm  -1.686e+00  1.131e-01 -14.898 < 2e-16 ***
## day              6.940e-03  4.110e-03  1.688 0.091345 .
## monthaug        -8.980e-01  1.290e-01 -6.962 3.36e-12 ***
## monthdec         1.111e+00  4.324e-01  2.570 0.010160 *
## monthfeb         7.374e-02  1.491e-01  0.495 0.620827
## monthjan         -1.352e+00  1.940e-01 -6.971 3.16e-12 ***
## monthjul         -1.113e+00  1.289e-01 -8.637 < 2e-16 ***
## monthjun         2.332e-01  1.538e-01  1.516 0.129462
## monthmar         1.598e+00  2.366e-01  6.754 1.44e-11 ***
## monthmay         -6.372e-01  1.235e-01 -5.159 2.48e-07 ***
## monthnov         -8.780e-01  1.400e-01 -6.270 3.62e-10 ***
## monthoct         1.163e+00  2.083e-01  5.585 2.34e-08 ***
## monthsep         1.450e+00  2.737e-01  5.297 1.17e-07 ***
## duration         5.865e-03  1.518e-04  38.625 < 2e-16 ***
## campaign         -8.706e-02  1.562e-02 -5.572 2.51e-08 ***
## pdays            -1.993e-05  4.903e-04 -0.041 0.967570
## previous         4.245e-02  1.828e-02  2.322 0.020250 *
## poutcomeother   4.015e-01  1.557e-01  2.578 0.009924 **
## poutcomesuccess 2.235e+00  1.619e-01  13.803 < 2e-16 ***
## poutcomeunknowm -2.944e-02  1.620e-01 -0.182 0.855796
## --- 
## Signif. codes:  0 '****' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## 
## (Dispersion parameter for binomial family taken to be 1)
## 
## Null deviance: 11731  on 8461  degrees of freedom
## Residual deviance: 6687  on 8420  degrees of freedom
## AIC: 6771
## 
## Number of Fisher Scoring iterations: 6

```

```
pseudo_r2 = pscl:::pR2(model_glm)[ "McFadden" ]
```

```
## fitting null model for pseudo-r2
```

```
pseudo_r2_2 = pscl:::pR2(model_glm2)[ "McFadden" ]
```

```
## fitting null model for pseudo-r2
```

```
pseudo_r2 ; pseudo_r2_2
```

```
## McFadden  
## 0.4299881
```

```
## McFadden  
## 0.429962
```

```
predict2 <- predict(model_glm2, testset ,type="response")  
head(predict2)
```

```
##      8       9      10      11      13      16  
## 0.9094505 0.9982244 0.3306641 0.9985548 0.9649953 0.4241437
```

Accuracy

```
cm2 <- InformationValue::confusionMatrix(testset$y, predictedScores = predict2)  
cm2
```

```
0  
1  
2 rows | 1-1 of 3 columns
```

```
accuracy2 <- (cm2[2,2]+cm2[1,1])/sum(cm2)  
accuracy2
```

```
## [1] 0.8460911
```

Recall

```
recall2<-(cm2[2,2])/(cm2[1,2]+cm2[2,2])  
recall2
```

```
## [1] 0.8043478
```

Recall değeri 0.8043478 bulunmuştur. Modelin pozitif örneklerin %80.43478'ini doğru bir şekilde tespit ettiği anlamına gelir.

Precision

Kesinlik (Precision) Positive olarak tahminlediğimiz değerlerin gerçekten kaç adedinin Positive olduğunu göstermektedir.

```
precision2 <- (cm2[2,2])/ (cm2[2,1]+cm2[2,2])  
precision2
```

```
## [1] 0.1350794
```

Yani model *müşteri vadeli mevduat aboneliği kabul olanları* %13.50794 kesinlikle tahmin edebiliyor şeklinde yorumlanabilir.

Sensitivity

Sensitivity(Duyarlılık) aslında Recall ile aynı formülüzasyona sahiptir.

```
sensitivity2<-(cm2[2,2])/(cm2[1,2]+cm2[2,2])  
sensitivity2
```

```
## [1] 0.8043478
```

Positive classları tahmin ederken ne kadar hassaslıkla tahminde bulunuluğunu gösterir. model2'nin confusion matrix'i için bu değeri %80.43478 olarak elde edildi.

Specificity

Negative classı ne kadar iyi tahmin edebildiğimizi gösteren bir metriktir. Bu durumda *mevduata abone olmama durumunu* tahmin etmedeki model başarısını gösterecektir.

```
specificity2<- (cm2[1,1])/(cm2[2,1]+cm2[1,1])
specificity2
```

```
## [1] 0.8473285
```

Accuracy değeriyle yakın bir değer(0.8473285) elde ettik. Metrikler üzerindeki gözlemlerimiz sonucunda modelimizin **doğru negatifleri bulmada** başarılı bir model olduğunu görebiliyoruz.

F1 Scoru

F1'in yüksek olması positive classların tahmininde modelin iyi olduğunu belirten bir ölçüt olarak kullanılabilir. Bizim modelimiz için iyi sonuç vermesini beklemeyiz.

```
f1_score2<-2*((precision2*recall2)/(precision2+recall2))
f1_score2
```

```
## [1] 0.2313129
```

Modelin mevduata abone olma durumunu tahmin etme F1 scoru %23 olarak elde edilmiştir. Bir kez daha modelin *mevduata abone olmama durumunu* tahmin etmede başarılı olduğunu vurgulayabiliriz.

ROC CURVE

Eğrinin altında kalan alan anlamını taşımaktadır. Alan büyüklüğü 0-1 arasındadır ve 1'e yakın değerler tercih edilir. Yani eğri altında kalan alan büyükükçe model iyileşir.

```
#install.packages("pROC")
library(pROC)
```

```
## Type 'citation("pROC")' for a citation.
```

```
##
## Attaching package: 'pROC'
```


```
## The following objects are masked from 'package:stats':
## cov, smooth, var
```

```
rocModel2<-roc(testset$y~predict2)
```

```
## Setting levels: control = no, case = yes
```

```
## Setting direction: controls < cases
```

```
plot(rocModel2)
```



Yukarıdaki görselde eğri altında kalan alanı gözlemleyebiliriz. Bir de sayısal değer olarak bakalım:

```
rocModel2
```

```
## 
## Call:
## roc.formula(formula = testset$y ~ predict2)
## 
## Data: predict2 in 35691 controls (testset$y no) < 1058 cases (testset$y yes).
## Area under the curve: 0.905
```

Area under the curve(eğri altında kalan alan) %90.5 olarak elde edilmiş ve gayet iyi bir sonuçtur.

Sonuç: Elde Edilen Tahmin Denklemi ve Yorumlanması

İlk olarak 1. model(model_glm) veri setine uygun olarak *binomial logistic regression* kullanılarak elde edilmiş ve katsayıları yorumlanmıştır. Daha sonrasında 2. model(model_glm_2) elde edilirken complexity'i düşürmek hedeflenerek anlamsız değişkenler modelden çıkarılmış ve confusionmatrix üzerinden metriklerle karşılaştırma yapılmış model yorumlanmıştır. Seçilen model(model_glm_2)'yi iyileştirmek için cut_off value belirlenmesi gibi çeşitli yollara gidilmiş ve uygun adımlar uygulanmıştır.


```
library(dplyr)

data <- data %>%
  mutate(age_group = cut(
    age,
    breaks = c(18, 25, 35, 45, 55, 65, 100),
    labels = c("18-25", "26-35", "36-45", "46-55", "56-65", "65+"),
    right = FALSE
  ))
```

```
summary_data <- data %>%
  group_by(age_group) %>%
  summarise(yas_bazinda_onay_orani = mean(y=="yes"),
            yas_bazinda_ortalama_butce = mean(balance))
```


```
library(ggplot2)
ggplot(summary_data, aes(x = age_group, y = yas_bazinda_onay_orani)) +
  geom_col() +
  labs(
    title = "Yaş Aralıklarına Göre Onay Oranı",
    x = "Yaş Aralığı",
    y = "Onay Oranı"
  ) +
  theme_minimal()
```

Yaş Aralıklarına Göre Onay Oranı



```
ggplot(summary_data, aes(x = age_group, y = yas_bazinda_ortalama_butce)) +  
  geom_col() +  
  labs(  
    title = "Yaş Aralıklarına Göre Ortalama Limit",  
    x = "Yaş Aralığı",  
    y = "Ortalama Bütçe"  
) +  
  theme_minimal()
```

Yaş Aralıklarına Göre Ortalama Limit



Bu iki grafikten anlaşılacağı üzere ortalama bütçe değişkeni onay oranı üzerinde kesin bir etkiye sahip değildir. Yaş aralığı arttıkça ortalama bütçe artmasına rağmen onay oranları orta yaş gruplarında düşük yüzdelerde seyir etmektedir.

Değişkenler Arasındaki Korelasyon Katsayıları

```
str(data)
```

```

## 'data.frame': 45211 obs. of 18 variables:
## $ age      : int 58 44 33 47 33 35 28 42 58 43 ...
## $ job       : Factor w/ 12 levels "admin.", "blue-collar", ...: 5 10 3 2 12 5 5 3 6 10 ...
## $ marital   : Factor w/ 3 levels "divorced", "married", ...: 2 3 2 2 3 2 3 1 2 3 ...
## $ education : Factor w/ 4 levels "primary", "secondary", ...: 3 2 2 4 4 3 3 3 1 2 ...
## $ default   : Factor w/ 2 levels "no", "yes": 1 1 1 1 1 1 2 1 1 ...
## $ balance   : int 2143 29 2 1506 1 231 447 2 121 593 ...
## $ housing   : Factor w/ 2 levels "no", "yes": 2 2 2 2 1 2 2 2 2 ...
## $ loan      : Factor w/ 2 levels "no", "yes": 1 1 2 1 1 1 2 1 1 ...
## $ contact   : Factor w/ 3 levels "cellular", "telephone", ...: 3 3 3 3 3 3 3 3 3 3 ...
## $ day       : int 5 5 5 5 5 5 5 5 ...
## $ month     : Factor w/ 12 levels "apr", "aug", "dec", ...: 9 9 9 9 9 9 9 9 9 9 ...
## $ duration  : int 261 151 76 92 198 139 217 380 50 55 ...
## $ campaign  : int 1 1 1 1 1 1 1 1 ...
## $ pdays     : int -1 -1 -1 -1 -1 -1 -1 -1 ...
## $ previous  : int 0 0 0 0 0 0 0 0 ...
## $ poutcome  : Factor w/ 4 levels "failure", "other", ...: 4 4 4 4 4 4 4 4 4 4 ...
## $ y         : Factor w/ 2 levels "no", "yes": 1 1 1 1 1 1 1 1 ...
## $ age_group: Factor w/ 6 levels "18-25", "26-35", ...: 5 3 2 4 2 3 2 3 5 3 ...

```

```

num_vars = names(data)[sapply(data, is.numeric)]

cor_mat <- cor(data[num_vars])

cor_list <- as.data.frame(as.table(cor_mat))

cor_list <- cor_list %>%
  dplyr::filter(Var1 != Var2) %>%
  dplyr::distinct()

cor_sorted <- cor_list %>%
  dplyr::arrange(desc(Freq))

head(cor_sorted)

```

1
2
3
4
5
6

6 rows | 1-1 of 4 columns

Modelin Test Seti Tahminleri

Bu adımda modelden, modele daha önce göstermediğimiz test seti gözlemlerini tahmin etmesini isteyeceğiz. Model kurulurken modeli eğitmek için eğitim-test seti olarak bölmüştük. Buradaki test set modelin hiç görmediği değerlerden oluşmaktadır. Karıştırılmamalıdır.

```

test_data <- read.csv("/Users/umutaykanat/Desktop/portfolio/banking data/test.csv", sep = ";", header = TRUE)
head(test_data)

```

1
2
3
4
5
6

6 rows | 1-1 of 18 columns

```
predict_test <- predict(model_glm,test_data,type="response")
head(predict_test)
```

```
##          1         2         3         4         5         6
## 0.59996667 0.13136447 0.43198681 0.04651941 0.03256433 0.59860116
```

```
library(devtools)
cm<-InformationValue::confusionMatrix(test_data$y, predictedScores = predict_test)
cm
```

0	
1	

2 rows | 1-1 of 3 columns

```
accuracy_test<-(cm[2,2]+cm[1,1])/sum(cm)
accuracy_test
```

```
## [1] 0.8378677
```

Test setine ilişkin tahminlerin accuray oranı **%83.7'dir**. Modelin test set üzerinde başarılı tahminler yaptığı söylenebiliriz.

TEŞEKKÜRLER

Umut Aykanat